CENG 4525 Introduction to Bioinformatics
Final Project Report

Student Information

Yeşim Arslan

yesimarslan@posta.mu.edu.tr

220709030

Name of Lecturers

Talip Zengin

LUNG CANCER RISK PREDICTION USING AUTOANTIBODY PROFILES

Abstract

This study investigates whether autoantibody profiles can serve as a potential biomarker source for early-stage assessment of lung cancer risk. Lung cancer has a high mortality rate and is most often diagnosed at advanced stages, which increases the importance of early screening approaches. Autoantibodies, produced by the immune system during the early phases of tumor development and detectable in circulation, represent a promising signal for non-invasive screening strategies. In this work, a machine learning–based risk prediction approach was developed using autoantibody intensity data from individuals with lung cancer and those without cancer. Comprehensive preprocessing, distributional assessment, and feature engineering were applied to raw intensity measurements, with a particular focus on correcting skewed distributions and identifying informative features. Logistic Regression was selected as the primary model due to its interpretability and suitability for clinical risk estimation. At the same time, Random Forest was used as a comparative reference model to capture non-linear relationships. Model performance was evaluated using standard classification metrics along with Receiver Operating Characteristic (ROC) curves and decision-threshold analysis. The results indicate that autoantibody profiles contain meaningful discriminative information between cancer and non-cancer groups. However, the model should be interpreted as a screening-oriented tool for identifying high-risk individuals rather than a definitive diagnostic instrument.

1. Introduction

Lung cancer remains one of the leading causes of cancer-related mortality worldwide. A primary reason for its high mortality is that clinical symptoms often emerge at advanced stages, while opportunities for early detection are limited. Current diagnostic procedures typically involve invasive methods, imaging techniques, or advanced clinical evaluations, which makes widespread, low-cost population screening in early stages difficult.

In this context, early risk identification and screening-oriented approaches have become increasingly important. The primary purpose of screening is not to establish a definitive diagnosis, but rather to identify individuals at elevated risk who would benefit from further clinical evaluation. This distinction is critical, and the concepts of screening and diagnosis must be separated both methodologically and ethically.

Autoantibodies have attracted attention in this field because they may be produced by the immune system during the earliest phases of tumor formation. Autoantibody responses to tumor antigens can arise before a clinically detectable tumor burden exists and can be measured stably in circulation. These properties make autoantibodies attractive candidates for non-invasive early risk assessment.

In recent years, machine learning methods have become widely used for analyzing high-dimensional biological data. However, in biomarker-based models, performance alone is not sufficient; interpretability, generalizability, and compatibility with the clinical context are equally important. In particular, screening-oriented systems benefit from probability-based outputs that

can be integrated into decision workflows.
This study presents a machine learning approach for predicting lung cancer risk using autoantibody intensity data. The dataset and analysis strategy were structured with biological relevance, statistical consistency, and clinical applicability in mind. The influence of data sources and dataset selection on the study outcomes is discussed in detail in the relevant section.

2. Biological Background: Autoantibodies & Lung Cancer

Cancer development is a dynamic process shaped not only by genetic and cellular changes, but also by complex interactions between the tumor and the immune system. Genetic mutations, abnormal protein expression, and post-translational modifications in tumor cells can lead to the emergence of tumor-associated antigens (TAAs) that may be recognized as "non-self" by the immune system.
A key component of the immune response to such antigens is autoantibody production. Autoantibodies are immunoglobulins produced by B cells against antigens expressed or released by tumor cells. Importantly, even in early cancer stages—before a clinically detectable tumor burden exists—the humoral immune response can become activated. This enables autoantibodies to carry biologically meaningful signals for early risk assessment.
In the early phase of humoral immunity, IgM-class antibodies often play a dominant role. IgM antibodies are produced rapidly after initial antigen exposure and are generally considered part of the immune system's early warning mechanism. Over time, class switching can produce higher-affinity IgG antibodies; however, changes in IgM levels may be particularly informative during early tumor development. Therefore, evaluating autoantibody profiles reflects not only the presence of antibodies, but also the timing and dynamics of immune activation.
Previous studies in lung cancer have shown that autoantibodies against targets such as p53, NY-ESO-1, and various cytoskeletal proteins can be detected even in early stages of disease. Nevertheless, the diagnostic accuracy of a single autoantibody is typically limited. Clinically meaningful discrimination generally requires the joint evaluation of multiple autoantibody signals, which increases the importance of statistical and computational methods for high-dimensional analysis.
The autoantibody intensity data used in this study contain hundreds of distinct signals per sample. While many signals may be weak or dominated by noise, a smaller subset can carry disease-related information. The core challenge is therefore to uncover biologically meaningful but statistically embedded patterns. Machine learning methods provide a framework for modeling the combined effect of autoantibody profiles beyond classical univariate analyses.

3. Data Source and Dataset Selection

The data used in this study were obtained from the NCBI Gene Expression Omnibus (GEO) repository. GEO is a reliable open-access resource that provides experimental biological datasets (e.g., microarray, RNA-seq, protein arrays) along with sample metadata, enabling reproducible reanalysis and validation. The goal of this project is not to develop a diagnostic

test that replaces invasive clinical procedures, but to build a serum-based, non-invasive screening approach capable of generating early risk signals. Therefore, dataset selection was guided not only by accessibility but also by biological suitability, clinical realism of the label structure, and direct alignment with the modeling objective.

3.1. The initially planned dataset and the need for change

At the beginning of the project, as stated in the proposal document, the plan was to work with a dataset based on peripheral blood gene expression profiles (the target dataset specified in the proposal was GSE40275). This approach followed a classical bioinformatics pipeline, including GEO data retrieval, probe-to-gene mapping, differential expression analysis, and machine learning modeling.

As the project progressed, two critical issues emerged:

a. **Clinical mismatch / label-structure problem:**
A screening-oriented model requires a labeling framework that realistically represents the question "Is there a cancer signal present or not?" In the initially planned data source, class structures and/or comparisons that did not directly support this objective—and that did not represent a true screening scenario—reduced alignment with the project's main purpose.

b. **Interpretability and reliability problem (critical rationale):**
During modeling attempts with the initial dataset, it was identified that the produced output was driven not by interpretable biological content in the data, but by synthetic/fabricated patterns, resulting in predictions that offered no meaningful value for risk interpretation. In other words, instead of learning a defensible biological signal, the approach produced analytically unreliable outputs that could not support clinical reasoning. Therefore, to ensure that the study output remained meaningful and scientifically defensible, the dataset choice was re-evaluated, and an alternative dataset was adopted.

This decision was not made to improve performance, but to ensure methodological validity, interpretability, and consistency with the study objective.

3.2. Final dataset: GSE168198

The final dataset used in this study is the GEO series GSE168198. This dataset contains autoantibody profiles obtained from human serum samples. Measurements were generated using protein microarray technology, and intensity values were recorded for a large number of autoantibody signals per serum sample. This serum-based structure aligns directly with the project's non-invasive screening objective, since serum autoantibody measurement reflects a biomarker-based screening framework that is closer to clinical practice.

3.2.1. **Sample structure and clinical realism**

GSE168198 consists of 196 human serum samples distributed across three groups:

- **NegativeControl:** healthy negative controls
- **DiseaseControl:** non-cancer diseases / clinically similar conditions
- **LungCancer:** lung cancer patients

This three-group structure is clinically more realistic, particularly because it includes the DiseaseControl group. In real screening scenarios, the model is not expected to distinguish only between "very healthy" individuals and cancer patients; it must also differentiate cancer from non-cancer conditions that may present overlapping symptoms or inflammatory/immune profiles. Therefore, a dataset that includes disease controls reflects the practical difficulty of clinical discrimination rather than an idealized separation.

3.3. Phase structure: rationale for handling Phase I and Phase II

GSE168198 contains two phases, which were intentionally used for different purposes in this study:

Phase I:

This phase has a very small sample size combined with extremely high dimensionality. In such "$n \ll p$" settings (very few samples, very many features), severe overfitting is expected. Therefore, Phase I was not considered suitable for reliable model training and was used only for exploratory assessment to understand the dataset structure.

Phase II:

This phase was used as the primary modeling dataset and contains approximately 180 samples. Its class distribution is more balanced and statistically more stable. Accordingly, all core modeling steps (preprocessing, EDA, feature selection, modeling, and evaluation) were performed exclusively on Phase II to increase the reliability and interpretability of results.

3.4. Labeling strategy (screening-oriented design)

Because the goal of this study is to generate a risk signal rather than a definitive diagnosis, the problem was formulated as a binary classification:

Cancer class: LungCancer

Non-cancer class: DiseaseControl + NegativeControl

This strategy reflects the screening question: "Is a cancer signal present?" Moreover, because the model outputs probabilities, the decision threshold can later be adjusted depending on clinical

context, which is a critical advantage for managing the sensitivity–false alarm trade-off in screening applications.

4. Data Preparation and Parsing

GEO datasets are not provided as ready-to-analyze tables in a classic row–column structure. Instead, sample metadata and measurement values are typically stored within the same file in separate sections. If loaded using standard table-reading functions, this structure can cause serious sample–label misalignment, which can invalidate modeling outcomes. In high-dimensional biological datasets, even a small alignment error can completely compromise results. The GSE168198 dataset exhibits this structure, and therefore, data preparation was treated not as a routine preprocessing step but as a critical phase determining analytical reliability.

4.1. Parsing the File Structure

GSE168198 data files include both sample descriptions (metadata) and the measurement table containing autoantibody intensities. The file was read line-by-line and explicitly separated into two components:

a. Sample metadata:
   - Sample identifiers (sample IDs)
   - Clinical group labels (NegativeControl, DiseaseControl, LungCancer)
   - Phase information (Phase I / Phase II)

b. Measurement table:
   - Rows represent autoantibodies/proteins
   - Columns correspond to serum samples
   - Entries contain raw intensity values

During parsing, file headers and section markers were carefully tracked, and the start and end of the measurement table were explicitly defined to prevent mixing metadata and measurement content.

4.2. Verification of sample–column alignment

The most critical step was verifying that the sample order in metadata exactly matched the column order in the measurement table. The following checks were performed:

• Whether sample IDs in metadata matched the column names in the measurement table exactly
• Whether any columns were missing or extra
• Whether ordering differences could lead to mislabeling

Only after these checks were satisfied was the dataset merged. This ensured that each autoantibody

intensity vector corresponded to the correct clinical label and eliminated risks of mislabeling or data leakage.

4.3. Phase filtering and construction of the final dataset

As justified earlier, only Phase II samples were included in modeling. Phase I samples were removed using phase information from metadata, and sample size and class distribution were re-validated after filtering.

Selecting Phase II:
• Increased the sample size to a more statistically reliable level
• Reduced severe overfitting risk
• Improved interpretability and generalizability of results

4.4. Label derivation and problem formulation

After cleaning and Phase II filtering, labels were re-defined according to the screening-oriented framework:

• LungCancer samples → Cancer class
• DiseaseControl + NegativeControl samples → Non-cancer class

This labeling directly reflects the central question: "Is a cancer signal present?"

At the end of this stage, two core components were constructed for modeling:

• x: feature matrix containing autoantibody intensities
• y: target vector containing binary class labels

4.5. Data Quality Checks

Finally, dataset quality was validated before modeling by checking:

• The presence of missing values
• Constant (zero-variance) features across all samples
• Whether extreme values were concentrated in specific samples

These checks indicated no technical issues that would directly compromise model learning, and the dataset was deemed ready for exploratory analysis and feature engineering.

5. Exploratory Data Analysis

Before moving to modeling, a comprehensive Exploratory Data Analysis (EDA) was conducted to understand the overall structure of the autoantibody intensity data, its distributional properties, and potential quality issues. The main goal was not to force class separation using

labels, but to examine the natural statistical behavior of the data and detect structural risks early. Identifying such issues at an early stage is essential for preventing misleading model conclusions.

5.1. Assessment of class distribution

As a first step, class distribution was examined on Phase II. The sample counts and proportions for cancer and non-cancer classes were evaluated to determine whether a severe imbalance existed that could distort modeling. Although the dataset was not perfectly balanced, it did not exhibit extreme imbalance. This structure is consistent with a screening scenario, where both sensitivity (recall) and false-alarm behavior must be considered jointly.

This observation also indicates that relying on a single metric, such as accuracy, would be insufficient, motivating the use of ROC curves and threshold-based analysis in later stages.

5.2. Sample-level intensity statistics

In protein microarray data, comparing global signal levels across samples is important for detecting technical variation and biological heterogeneity. For this purpose, median intensity was calculated for each sample. The median is robust to extreme values and provides a stable summary of overall signal level.

The distribution of sample medians showed that most samples clustered within a certain range, with a subset of high-intensity samples forming a right tail. This pattern suggests right-skewed signal behavior. High-intensity samples may reflect strong biological immune responses or technical variation. In either case, feeding such skewed data directly into a model can cause learning to be dominated by a small number of extreme observations.

5.3. Within-sample variability (IQR analysis)

Beyond the global signal level, variability within each sample was analyzed using the interquartile range (IQR). IQR summarizes the spread of autoantibody intensities within a sample and reflects signal heterogeneity.

The IQR distribution indicated that some samples had relatively homogeneous autoantibody profiles, while others showed substantial heterogeneity. This is biologically plausible: cancer cases may exhibit strong responses to a subset of antigens, whereas healthy or disease controls may present flatter profiles. This heterogeneity supports the need to evaluate combinations of autoantibodies rather than relying on single markers.

5.4. Global structure via label-free PCA

To assess overall structure, Principal Component Analysis (PCA) was performed without using class labels. This analysis addressed two key questions:

a. Is there evidence of batch effects or technical separation?
b. Do samples show unusual clustering or strong outliers in low-dimensional space?

The PCA results suggested that samples occupied a shared space without strong technical separation, indicating no dominant batch effect. A small number of potential outliers were observed, which is expected in immune profiling and may reflect strong individual responses. These were not automatically removed; instead, subsequent transformations and modeling choices were used to control their influence.

Importantly, classes did not separate clearly in the PCA space. This does not indicate failure; rather, it confirms that the task is non-trivial. If cancer and non-cancer separated linearly at the PCA level, simple thresholding could have been sufficient. The observed structure implies that separation depends on subtle, multi-dimensional patterns, motivating machine learning approaches.

5.5. EDA bulgularının modelleme açısından çıkarımları

Keşifsel analizden elde edilen bulgular, sonraki adımlar için üç temel sonucu netleştirmiştir:

a. **Dağılım çarpıklığı:**
Otoantikor yoğunlukları sağa çarpık dağılımlar sergilemektedir. Bu durum, varyansın stabilize edilmesi ve modelin uç değerlere aşırı duyarlı hale gelmemesi için dönüşüm gereksinimini doğurmuştur.
b. **Heterojen sinyal yapısı:**
Tek bir otoantikor sinyalinin yeterli olmayacağı; anlamlı ayrımın çoklu sinyallerin birlikte değerlendirilmesiyle mümkün olacağı görülmüştür.
c. **Non-trivial sınıf ayrımı:**
Sınıflar arasında açık ve lineer bir ayrım bulunmaması, problem için hem yorumlanabilir hem de esnek modelleme yaklaşımlarının birlikte değerlendirilmesini gerektirmiştir.

Bu bulgular doğrultusunda, bir sonraki aşamada **özellik mühendisliği ve özellik seçimi** adımlarına geçilmiş; özellikle dağılım dönüşümleri ve bilgi taşıyan otoantikorların belirlenmesine odaklanılmıştır.

6. Feature Engineering and Selection

Otoantikor mikroarray verileri, her bir örnek için yüzlerce hatta binlerce potansiyel özellik (otoantikor sinyali) içermektedir. Bu tür yüksek boyutlu biyolojik verilerde, ham özelliklerin doğrudan modele verilmesi hem istatistiksel hem de biyolojik açıdan sorunlara yol açabilir. Bu nedenle, modelleme öncesinde özelliklerin dağılım özelliklerinin düzeltilmesi ve gerçekten bilgi taşıyan otoantikorların seçilmesi gerekmektedir. Bu bölümde uygulanan özellik mühendisliği ve özellik seçimi adımları, keşifsel analizden elde edilen bulgulara dayalı olarak yapılandırılmıştır.

6.1. Dağılım dönüşümü: log1p transformasyonu

EDA aşamasında, otoantikor yoğunluklarının belirgin biçimde **sağa çarpık (right-skewed)** dağılımlar sergilediği gözlemlenmiştir. Ham yoğunluk uzayında, örneklerin büyük bir kısmı düşük sinyal seviyelerinde yoğunlaşırken, sınırlı sayıda örnek çok yüksek yoğunluk

değerlerine sahiptir. Bu tür bir dağılım yapısı, birçok makine öğrenmesi algoritması için problematiktir; çünkü model, birkaç yüksek değerli gözlem tarafından aşırı derecede etkilenebilir ve genellenebilir örüntüler yerine uç noktalara odaklanabilir.

Bu problemi gidermek amacıyla, tüm otoantikor yoğunluk değerlerine **log1p dönüşümü** uygulanmıştır. log1p fonksiyonu (log(1+x)), sıfıra yakın değerleri korurken yüksek değerleri sıkıştırarak dağılımın daha simetrik hale gelmesini sağlar. Bu dönüşümün tercih edilme nedenleri şunlardır:

- Varyansın stabilize edilmesi
- Uç değerlerin model üzerindeki etkisinin azaltılması
- Özellikler arası ölçek farklarının azaltılması
- Özellikle doğrusal modellere (örneğin Logistic Regression) daha uygun bir veri uzayı oluşturulması

Dönüşüm sonrasında, otoantikor sinyallerinin dağılımlarının daha dengeli hale geldiği ve örnekler arası karşılaştırılabilirliğin arttığı gözlemlenmiştir. Bu adım, sonraki özellik seçimi ve modelleme aşamalarının temelini oluşturmaktadır.

6.2. Etiket bağımsız yapının korunması

Özellik mühendisliği sürecinde, sınıf etiketlerinin doğrudan kullanılması bilinçli olarak sınırlandırılmıştır. Bunun temel nedeni, erken aşamada aşırı etiket bağımlı işlemlerin modele dolaylı veri sızıntısı (data leakage) riski yaratabilmesidir. log1p dönüşümü gibi dağılım tabanlı işlemler, tüm veri setine etiketlerden bağımsız olarak uygulanmış; böylece veri uzayının genel yapısı korunmuştur.

Bu yaklaşım, özellik seçimi aşamasında kullanılacak etiket tabanlı ölçütlerin etkisinin daha kontrollü ve yorumlanabilir olmasını sağlamaktadır.

6.3. Univariate AUC ile ayırt edicilik analizi

Özellik seçiminin ilk adımında, her bir otoantikor sinyalinin **tek başına** kanser ve non-cancer örneklerini ayırt etme gücü değerlendirilmiştir. Bu amaçla, her özellik için **univariate ROC-AUC** değeri hesaplanmıştır. AUC metriği, belirli bir eşik değerine bağlı olmaksızın, bir özelliğin iki sınıfı ayırt etme yeteneğini ölçtüğü için bu bağlamda uygun bir ölçüttür.

AUC = 0.5 değeri, rastgele tahmin seviyesini temsil etmektedir. Bu nedenle:

- AUC ≈ 0.5 olan otoantikorlar, sınıflar arasında ayırt edici bilgi taşımayan özellikler olarak değerlendirilmiştir.
- AUC > 0.5 olan otoantikorlar ise potansiyel olarak bilgi taşıyan aday özellikler olarak ele alınmıştır.

Bu analiz, her bir otoantikorun **marjinal (tek değişkenli)** ayırt edicilik gücünü ortaya koymuş; ancak tek başına yeterli bir seçim kriteri olarak görülmemiştir. Bunun temel nedeni, biyolojik

sistemlerde anlamlı sinyallerin çoğu zaman tek bir değişken üzerinden değil, değişkenler arası etkileşimler yoluyla ortaya çıkmasıdır.

6.4. Mutual Information ile doğrusal olmayan bağımlılıkların yakalanması

Univariate AUC, bir özelliğin sınıf etiketini ayırt etme gücünü ölçse de, yalnızca belirli tipte ilişkileri yakalayabilir. Özellikle doğrusal olmayan veya daha karmaşık bağımlılık yapıları, AUC metriği ile tam olarak yansıtılamayabilir. Bu nedenle ikinci bir ölçüt olarak **Mutual Information (MI)** kullanılmıştır.

Mutual Information, bir değişken ile hedef etiket arasındaki genel bağımlılığı ölçer ve doğrusal olmayan ilişkileri de kapsar. MI = 0 değeri, iki değişken arasında hiçbir bilgi paylaşımı olmadığını; MI > 0 ise bir miktar bilgi aktarımı olduğunu gösterir. Bu çalışmada:

- MI = 0 olan otoantikorlar, sınıf etiketiyle anlamlı bir ilişki taşımayan özellikler olarak elenmiştir.
- MI > 0 olan otoantikorlar, potansiyel olarak bilgi taşıyan adaylar olarak değerlendirilmiştir.

Bu adım, yalnızca tek başına güçlü görünen değil; **sınıfla tutarlı biçimde ilişkili** otoantikorların seçilmesine olanak tanımıştır.

6.5. Birleşik özellik seçimi stratejisi (AUC + MI)

Son özellik kümesi, **iki ölçütü birlikte sağlayan** otoantikorlardan oluşturulmuştur:

a. Univariate AUC değeri rastgele tahmin seviyesinin üzerinde olan
b. Mutual Information değeri sıfırdan büyük olan

Bu birleşik strateji, yalnızca istatistiksel gürültüye dayalı görünen özelliklerin elenmesini; buna karşılık hem ayırt edici hem de sınıfla tutarlı bilgi taşıyan otoantikorların korunmasını sağlamıştır. Bu yaklaşım, yüksek boyutlu biyolojik verilerde sık karşılaşılan "çok sayıda zayıf özellik" problemine karşı kontrollü bir çözüm sunmaktadır.

Özellik seçimi sonrasında elde edilen özellik matrisi, daha düşük boyutlu, daha az gürültülü ve modelleme açısından daha istikrarlı bir yapı kazanmıştır. Bu yapı, hem yorumlanabilir modellerin (örneğin Logistic Regression) hem de daha esnek yöntemlerin (örneğin Random Forest) etkin biçimde eğitilmesine olanak tanımıştır.

7. Modeling Approach

Bu çalışmada modelleme stratejisi belirlenirken, amaç yalnızca yüksek sınıflandırma başarısı elde etmek değil; aynı zamanda **model çıktılarının yorumlanabilir**, **klinik bağlamla uyumlu** ve **tarama (screening) senaryolarına uygun**olması hedeflenmiştir. Bu nedenle, tek bir model yerine, farklı varsayımlara ve güçlü yönlere sahip iki ayrı yaklaşım birlikte değerlendirilmiştir.

7.1. Problem formülasyonu ve çıktı türü

Çalışma problemi, otoantikor profillerine dayanarak bireylerin akciğer kanseri riski taşıyıp taşımadığını tahmin etmeye yönelik **ikili sınıflandırma (binary classification)** problemi olarak ele alınmıştır. Ancak bu sınıflandırma, "kesin tanı" üretmeyi amaçlayan bir yapıdan ziyade, **olasılık temelli risk skoru** üretmeye odaklanmaktadır.

Bu tercih bilinçlidir. Tarama senaryolarında, modelin çıktısı genellikle doğrudan klinik karar yerine, **ikincil değerlendirme gerektiren bireyleri işaretleyen bir sinyal** olarak kullanılır. Dolayısıyla modelin, yalnızca sınıf etiketi değil, aynı zamanda **olasılık değeri** üretmesi kritik öneme sahiptir.

7.2. Ana model: Logistic Regression

Bu çalışmada **Logistic Regression**, temel ve ana model olarak seçilmiştir. Bu seçimin arkasında birden fazla metodolojik ve klinik gerekçe bulunmaktadır:

a. **Yorumlanabilirlik:**
Logistic Regression, doğrusal bir karar sınırı kullanır ve her bir özelliğin (otoantikorun) çıktı üzerindeki etkisini katsayılar aracılığıyla açık biçimde ifade eder. Bu özellik, biyolojik verilerde modelin "neye dayanarak karar verdiğinin" anlaşılabilmesi açısından büyük bir avantajdır.

b. **Olasılık temelli çıktı:**
Model, her birey için 0–1 aralığında bir olasılık değeri üretir. Bu değer, "kanser var/yok" gibi sert bir karar yerine, **risk derecesi** olarak yorumlanabilir. Tarama uygulamalarında bu tür esnek çıktıların klinik değeri daha yüksektir.

c. **Aşırı uyum (overfitting) kontrolü:**
Özellik seçimi sonrası bile veri seti görece yüksek boyutlu bir yapı sergilemektedir. Logistic Regression, uygun düzenlileştirme (regularization) ile birlikte kullanıldığında, küçük ve orta ölçekli veri setlerinde daha kararlı sonuçlar üretebilmektedir.

Bu nedenlerle Logistic Regression, çalışmanın temel modeli olarak konumlandırılmış ve tüm değerlendirmeler bu model üzerinden yorumlanmıştır.

7.3. Karşılaştırmalı model: Random Forest

Logistic Regression'ın doğrusal varsayımına ek olarak, otoantikor profillerindeki **doğrusal olmayan ilişkileri**yakalayabilmek amacıyla **Random Forest** modeli ikinci bir yöntem olarak kullanılmıştır. Random Forest, birden fazla karar ağacının bir araya gelmesiyle oluşturulan, esnek ve güçlü bir topluluk (ensemble) yöntemidir.

Random Forest'ın bu çalışmadaki rolü şunlardır:

- Otoantikorlar arasındaki karmaşık ve doğrusal olmayan etkileşimleri yakalayabilme
- Logistic Regression ile elde edilen sonuçlar için bir **referans (benchmark)** oluşturma
- Model performansının, yalnızca doğrusal varsayımlara bağlı olmadığını test etme

Ancak Random Forest, doğası gereği daha az yorumlanabilir bir modeldir. Bu nedenle çalışmada Random Forest, ana klinik aday model olarak değil; Logistic Regression sonuçlarını destekleyici ve karşılaştırmalı bir araç olarak ele alınmıştır.

7.4. Eğitim–test ayrımı ve model eğitimi

Modeller, daha önce tanımlanan şekilde **stratified train–test split** ile ayrılmış veri üzerinde eğitilmiştir. Eğitim seti, model parametrelerinin öğrenilmesi için kullanılırken; test seti, modelin daha önce görmediği örnekler üzerindeki genelleme performansını değerlendirmek için ayrılmıştır.

Bu ayrım, modelin yalnızca eğitim verisini ezberlemediğini; yeni bireyler üzerinde de anlamlı tahminler üretebildiğini göstermek açısından gereklidir. Tüm ön işleme ve özellik seçimi adımları, eğitim–test ayrımı sonrasında tutarlı biçimde uygulanmıştır.

7.5. Modelleme yaklaşımının genel gerekçesi

Özetle, bu çalışmada izlenen modelleme stratejisi şu prensiplere dayanmaktadır:

- **Yorumlanabilirlik önceliği:** Klinik bağlamda anlaşılabilir modeller tercih edilmiştir.
- **Esnek referans karşılaştırması:** Doğrusal olmayan ilişkileri yakalayabilen bir model ile karşılaştırma yapılmıştır.
- **Tarama odaklı tasarım:** Model çıktıları, kesin tanıdan ziyade risk sinyali üretmeye yöneliktir.

Bu yaklaşım, bir sonraki bölümde ayrıntılı olarak ele alınacak olan **model değerlendirme metriklerinin** de nasıl ve neden seçildiğini doğrudan etkilemiştir.

8. Model Evaluation

Model değerlendirme süreci, çalışmanın tarama (screening) odaklı hedefi göz önünde bulundurularak yapılandırılmıştır. Bu bağlamda, tek bir performans metriğine dayanmak yerine, model davranışını farklı açılardan inceleyen çoklu değerlendirme ölçütleri kullanılmıştır. Özellikle sınıf dengesizliği bulunan biyomedikal problemlerde, yalnızca doğruluk (accuracy) metriğine odaklanmak yanıltıcı sonuçlara yol açabilir.

8.1. Neden accuracy tek başına yeterli değildir?

İkili sınıflandırma problemlerinde accuracy, doğru tahmin edilen örneklerin toplam örneklere oranını ifade eder. Ancak sınıflar arasında dengesizlik bulunduğunda, model çoğunluk sınıfı tahmin ederek yüksek accuracy değerleri elde edebilirken, klinik olarak en kritik sınıf olan kanserli bireyleri kaçırabilir.

Bu çalışmada, non-cancer sınıfının sayıca daha fazla olması, yalnızca accuracy odaklı bir değerlendirmenin **kanser vakalarının göz ardı edilmesi** riskini doğurmaktadır. Bu nedenle model performansı, sınıf bazlı metriklerle ve eşik bağımsız ölçütlerle birlikte ele alınmıştır.

8.2. Precision, Recall ve F1-score

Model performansının sınıf bazlı değerlendirilmesi için aşağıdaki metrikler hesaplanmıştır:

- **Precision (Kesinlik):**
  Modelin "kanser" olarak işaretlediği örneklerin ne kadarının gerçekten kanser olduğunu gösterir. Yüksek precision, yanlış pozitif oranının düşük olduğunu ifade eder.
- **Recall (Duyarlılık):**
  Gerçek kanser vakalarının ne kadarının model tarafından doğru biçimde tespit edildiğini ölçer. Tarama senaryolarında recall, klinik açıdan en kritik metriktir; çünkü kaçırılan kanser vakaları geri kazanılamaz.
- **F1-score:**
  Precision ve recall'un harmonik ortalamasıdır ve iki metrik arasındaki dengeyi özetler.

Varsayılan karar eşiği (threshold = 0.5) kullanıldığında, modellerin precision değerlerinin görece makul olduğu; ancak recall değerlerinin düşük kaldığı gözlemlenmiştir. Bu sonuç, modelin yüksek güvenle tahmin yapma eğiliminde olduğunu, ancak bu yaklaşımın önemli sayıda kanser vakasını kaçırdığını göstermektedir. Bu durum bir modelleme hatası değil, sabit ve yüksek bir eşik değerinin doğal sonucudur.

8.3. ROC eğrileri ve AUC metriği

Model performansını eşik değerinden bağımsız olarak değerlendirmek amacıyla **Receiver Operating Characteristic (ROC)** eğrileri ve **Area Under the Curve (AUC)** metriği kullanılmıştır. ROC eğrisi, farklı eşik değerleri altında duyarlılık (true positive rate) ile yanlış pozitif oranı (false positive rate) arasındaki değişimi göstermektedir.

AUC değeri, modelin rastgele bir kanserli bireyi rastgele bir non-cancer bireyden ayırt edebilme olasılığını temsil eder. AUC = 0.5, rastgele tahmin seviyesini; 1.0 ise kusursuz ayrımı ifade eder.

Bu çalışmada:

- **Random Forest**, daha yüksek AUC değerleri elde ederek güçlü bir ayırt edicilik sergilemiştir.
- **Logistic Regression** ise daha düşük olmakla birlikte, rastgele tahminin belirgin şekilde üzerinde performans göstermiştir.

Bu sonuçlar, otoantikor profillerinin sınıflar arasında anlamlı bir ayırt edici sinyal içerdiğini desteklemektedir. Aynı zamanda, doğrusal olmayan ilişkilerin Random Forest tarafından daha iyi yakalanabildiğini; ancak Logistic Regression'ın da klinik bağlamda kabul edilebilir bir performans sunduğunu göstermektedir.

8.4. Tarama perspektifinden performansın yorumu

Model değerlendirme sonuçları, çalışmanın temel hedefi olan **erken risk taraması** perspektifinden yorumlanmalıdır. Klinik tanı testlerinde yüksek precision ön plandayken, tarama testlerinde **yüksek recall** genellikle daha kritiktir. Bunun nedeni, yanlış pozitif sonuçların ek testlerle elenebilmesine karşın, kaçırılan gerçek vakaların ciddi sonuçlara yol açabilmesidir.

Bu bağlamda, varsayılan eşik değeriyle elde edilen düşük recall değerleri, modelin başarısızlığı olarak değil; **eşik ayarlaması gerektiren bir risk sinyali üretici** olarak değerlendirilmelidir. Bu gözlem, bir sonraki bölümde ele alınacak olan **karar eşiği (threshold) analizinin** neden merkezi bir rol oynadığını doğrudan açıklamaktadır.

9. Threshold Analysis

İkili sınıflandırma modellerinde, özellikle olasılık temelli çıktı üreten yöntemlerde, model performansı yalnızca öğrenilen parametrelere değil; **karar eşiği (decision threshold)** seçimine de doğrudan bağlıdır. Varsayılan olarak birçok sınıflandırma algoritması, olasılık değeri **0.5**'in üzerinde olan örnekleri pozitif sınıfa atar. Ancak bu varsayılan eşik, her problem ve her klinik senaryo için uygun değildir.

Bu çalışmada, model çıktılarının tarama (screening) amaçlı kullanılması hedeflendiğinden, karar eşiğinin etkisi özel olarak incelenmiştir.

9.1. Varsayılan eşik (threshold = 0.5) altındaki model davranışı

Varsayılan eşik değeri kullanıldığında, Logistic Regression modeli görece **yüksek precision** ancak **düşük recall**üretmiştir. Bu, modelin yalnızca yüksek güvenle kanser olarak değerlendirdiği bireyleri pozitif sınıfa atadığını; buna karşılık gerçek kanser vakalarının önemli bir kısmını kaçırdığını göstermektedir.

Bu davranış, modelin yanlış öğrenmesinden değil; yüksek eşik değerinin doğal sonucundan kaynaklanmaktadır. Olasılık dağılımı incelendiğinde, birçok kanserli bireyin tahmin edilen risk değerlerinin 0.5'in altında kaldığı görülmektedir. Bu durum, sabit ve yüksek bir eşik değerinin tarama senaryoları için uygun olmadığını göstermektedir.

9.2. Düşük eşik değeri ile duyarlılığın artırılması

Tarama uygulamalarında temel öncelik, mümkün olduğunca az sayıda kanser vakasının kaçırılmasıdır. Bu nedenle karar eşiği **0.5'ten daha düşük bir değere** çekilerek model davranışı yeniden değerlendirilmiştir. Bu çalışmada, eşik değeri **0.2**olarak belirlenmiştir.

Eşik değerinin 0.2'ye düşürülmesiyle birlikte:

- **Recall (duyarlılık)** belirgin biçimde artmış

- Model, kanserli bireylerin yaklaşık **%89'unu** doğru şekilde tespit edebilir hale gelmiştir
- Buna karşılık, **false positive** oranında artış gözlemlenmiştir

Bu değişim, modelin daha "temkinli" bir şekilde risk sinyali üretmeye başladığını göstermektedir. Yani model, düşük düzeyde dahi olsa kanser sinyali taşıyan bireyleri dışlamamayı tercih etmektedir.

9.3. Yanlış pozitiflerin klinik yorumu

Yanlış pozitif sonuçların artması, tarama senaryolarında her zaman olumsuz bir durum olarak değerlendirilmemelidir. Tarama testlerinin temel işlevi, nihai tanıyı koymak değil; **ikinci aşama klinik değerlendirmeden fayda görebilecek bireyleri işaretlemektir**.

Bu bağlamda:

- **Yanlış pozitifler**, ileri görüntüleme veya biyokimyasal testlerle elenebilir
- **Yanlış negatifler** (kaçırılan kanser vakaları) ise klinik açıdan geri döndürülemez sonuçlara yol açabilir

Bu nedenle, eşik değeri düşürülerek recall'un artırılması, çalışmanın tarama odaklı hedefiyle doğrudan uyumludur ve bilinçli bir tasarım tercihidir.

9.4. Karar eşiğinin ayarlanabilir bir parametre olarak ele alınması

Bu çalışmada karar eşiği sabit bir değer olarak değil; **kullanım senaryosuna bağlı olarak ayarlanabilir bir parametre**olarak ele alınmıştır. Klinik bağlamda, eşik değeri:

- Popülasyon risk profiline
- Sağlık sisteminin yanlış pozitifleri tolere edebilme kapasitesine
- Tarama testinin ikinci aşama maliyetlerine

göre dinamik olarak belirlenebilir.

Bu yaklaşım, modeli katı bir "evet/hayır" karar mekanizmasından çıkararak, **esnek bir risk sinyali üreticisi** haline getirmektedir. Bu esneklik, otoantikor temelli risk değerlendirme sistemlerinin gerçek dünya tarama uygulamalarına entegre edilebilmesi açısından kritik bir avantaj sunmaktadır.

10.Individual Risk Prediction

Bu çalışmada geliştirilen model, yalnızca toplu performans metrikleri üretmekle kalmayıp, **her bir birey için ayrı bir risk skoru** hesaplayacak şekilde tasarlanmıştır. Tarama odaklı uygulamalarda, bireysel düzeyde risk tahmini, ikili sınıf kararlarından daha bilgilendirici ve klinik açıdan daha kullanışlıdır. Bu nedenle model çıktıları, birey bazında yorumlanabilecek şekilde değerlendirilmiştir.

10.1. Olasılık temelli risk skorlarının üretimi

Logistic Regression modeli, her bir test örneği için 0 ile 1 arasında değişen bir olasılık değeri üretmektedir. Bu değer, ilgili bireyin otoantikor profiline dayanarak **kanser sınıfına ait olma olasılığını** temsil etmektedir. Bu olasılık, kesin bir tanı anlamına gelmemekte; aksine bireyin göreli risk düzeyini yansıtan sürekli bir ölçüt olarak ele alınmaktadır.

Bu yaklaşım, bireylerin yalnızca "kanser / kanser değil" şeklinde ikili olarak etiketlenmesinin ötesine geçerek, **risk spektrumu** üzerinde konumlandırılmasına olanak tanır. Böylece klinik karar vericiler, risk düzeyi yüksek bireyleri önceliklendirebilirken, düşük riskli bireyler gereksiz ileri testlerden kaçınabilir.

10.2. Eşik değerine bağlı bireysel sınıflandırma

Önceki bölümde tartışıldığı üzere, bu çalışmada karar eşiği **0.2** olarak belirlenmiştir. Bu eşik değeri kullanılarak:

- Olasılık ≥ 0.2 olan bireyler → *yüksek risk*
- Olasılık < 0.2 olan bireyler → *düşük risk*

olarak sınıflandırılmıştır. Bu sınıflandırma, tarama perspektifiyle uyumlu olup, duyarlılığı (recall) ön planda tutan bir yaklaşımı temsil etmektedir.

Bu çerçevede, bireysel tahminler incelendiğinde, modelin hem doğru pozitifleri hem de yanlış pozitif ve yanlış negatif örnekleri açık biçimde ayırt edebildiği görülmektedir. Özellikle yanlış pozitif ve yanlış negatif örneklerin bireysel düzeyde izlenebilir olması, modelin güçlü ve zayıf yönlerinin şeffaf biçimde analiz edilmesine olanak tanımaktadır.

10.3. Yanlış sınıflandırmaların bireysel düzeyde yorumu

Bireysel risk tahminlerinin değerlendirilmesi, modelin davranışını daha derinlemesine anlamayı sağlar. Yanlış pozitif olarak işaretlenen bireyler, otoantikor profilleri bakımından kanserli bireylere benzer sinyaller taşıyor olabilir. Bu durum, bu bireylerin gerçekten artmış bir risk grubunda olabileceğini veya inflamatuvar/immünolojik süreçler nedeniyle benzer yanıtlar sergilediklerini düşündürmektedir.

Öte yandan, yanlış negatif olarak sınıflandırılan bireyler, otoantikor profilleri açısından daha zayıf veya atipik bir immün yanıt sergileyebilir. Bu tür vakalar, otoantikor sinyalinin bireyler arasında heterojen olduğunu ve tek bir biyobelirteç setinin tüm vakaları yakalamasının zor olduğunu göstermektedir. Bu gözlemler, modelin sınırlılıklarını ortaya koyarken, aynı zamanda gelecekte yapılabilecek iyileştirmelere de ışık tutmaktadır.

10.4. İkili karardan risk sıralamasına geçiş

Bireysel olasılık skorlarının en önemli avantajlarından biri, bireylerin **risk sıralaması (risk ranking)** yapılabilmesidir. Model çıktıları, bireyleri yüksekten düşüğe doğru sıralayarak, tarama

programlarında kaynakların daha etkin kullanılmasına katkı sağlayabilir. Örneğin, en yüksek risk skoruna sahip bireyler daha hızlı ileri tetkiklere yönlendirilirken, düşük riskli bireyler izlem altında tutulabilir.

Bu yaklaşım, modeli katı bir sınıflandırma aracından çıkarıp, **klinik karar destek sistemine** daha yakın bir konuma taşımaktadır. Böylece model, tek başına karar veren bir yapı olmaktan ziyade, klinik değerlendirmeyi destekleyen bir yardımcı araç olarak konumlandırılmaktadır.

11.Discussion

Bu çalışmanın temel bulgusu, serum bazlı otoantikor profillerinin akciğer kanseri ile kanser olmayan bireyler arasında ayırt edici bir biyolojik sinyal taşıdığıdır. Model performansının mutlak anlamda yüksek olmaması, bu sinyalin önemsiz olduğu anlamına gelmemekte; aksine sinyalin **ince, çok boyutlu ve heterojen** bir yapıya sahip olduğunu göstermektedir. Bu durum, kanser biyolojisinin ve immün yanıtın doğasıyla uyumludur. Otoantikor yanıtı, tümör yüküne, antijen çeşitliliğine ve bireysel bağışıklık özelliklerine bağlı olarak büyük değişkenlik gösterebilmektedir.

Modelleme sonuçları, otoantikor sinyallerinin tekil ve güçlü bir biyobelirteçten ziyade, **çoklu zayıf sinyallerin birleşimi**şeklinde anlam kazandığını ortaya koymaktadır. PCA analizinde sınıfların açık biçimde ayrışmaması, bu gözlemi desteklemektedir. Eğer sınıflar düşük boyutlu uzayda net biçimde ayrışsaydı, basit kural tabanlı veya eşik temelli yöntemler yeterli olabilirdi. Ancak gözlemlenen yapı, ayrımın ancak çoklu özelliklerin birlikte değerlendirilmesiyle mümkün olduğunu göstermektedir.

Logistic Regression ve Random Forest sonuçlarının birlikte değerlendirilmesi, bu bağlamda önemli bir karşılaştırma sunmaktadır. Random Forest'ın daha yüksek AUC değerleri elde etmesi, otoantikor profilleri arasında doğrusal olmayan ilişkilerin bulunduğunu düşündürmektedir. Buna karşın Logistic Regression'ın daha düşük fakat istikrarlı performansı ve yüksek yorumlanabilirliği, tarama amaçlı klinik uygulamalar açısından daha uygun bir aday model olduğunu göstermektedir. Bu durum, model seçiminde "en yüksek performans" yerine "en uygun kullanım bağlamı" yaklaşımının benimsenmesi gerektiğini ortaya koymaktadır.

Bu çalışmada özellikle vurgulanan bir diğer nokta, **screening ve diagnosis kavramlarının net biçimde ayrılmasıdır**. Model çıktıları, kesin tanı koymak için değil; ileri klinik değerlendirmeden fayda görebilecek bireyleri erken aşamada işaretlemek için tasarlanmıştır. Bu nedenle, model başarısı tek bir eşik değeri veya tek bir performans metriği üzerinden değerlendirilmemelidir. Aksine, eşik ayarlaması yoluyla duyarlılık–yanlış alarm dengesi kurulabilmesi, modelin gerçek değerini belirleyen temel unsurdur.

Karar eşiğinin düşürülmesiyle elde edilen yüksek recall değerleri, modelin tarama senaryoları için uygun şekilde davranabildiğini göstermektedir. Yanlış pozitiflerin artması, bu bağlamda bir hata değil; tarama sistemlerinin doğasında bulunan ve klinik olarak tolere edilebilir bir sonuçtur. Bu yaklaşım, modelin "kesin karar verici" değil, **risk sinyali üreten bir ön filtre** olarak konumlandırılmasını sağlamaktadır.

12.Limitations and Future Work

Bu çalışmanın en önemli sınırlılıklarından biri, **örnek sayısının görece sınırlı olmasıdır**. Her ne kadar Phase II verileri istatistiksel olarak daha dengeli ve güvenilir bir yapı sunsa da, daha büyük ve farklı popülasyonları içeren veri setleriyle doğrulama yapılmadan klinik genellenebilirlik konusunda kesin çıkarımlar yapmak mümkün değildir. Özellikle otoantikor profillerinin popülasyonlar arasında değişkenlik gösterebileceği göz önünde bulundurulmalıdır.

Bir diğer önemli sınırlılık, çalışmada **harici (external) bir doğrulama veri setinin bulunmamasıdır**. Tüm analizler tek bir veri seti üzerinde gerçekleştirilmiştir. Bu durum, modelin farklı laboratuvar koşulları, farklı ölçüm platformları veya farklı klinik popülasyonlar altında nasıl davranacağına dair belirsizlik yaratmaktadır. Gelecek çalışmalarda, bağımsız veri setleri üzerinde doğrulama yapılması kritik önem taşımaktadır.

Modelleme açısından bakıldığında, yalnızca otoantikor profillerine dayalı bir yaklaşım izlenmiştir. Oysa klinik pratikte akciğer kanseri riski, yaş, cinsiyet, sigara kullanımı, aile öyküsü gibi birçok faktörün birleşimiyle şekillenmektedir. Gelecek çalışmalarda, otoantikor verilerinin bu klinik risk faktörleriyle entegre edilmesi, risk tahmininin doğruluğunu ve klinik değerini artırabilir.

Ayrıca, bu çalışmada seçilen özelliklerin biyolojik yorumlanması sınırlı tutulmuştur. Gelecek çalışmalar, model tarafından seçilen otoantikorların hedef aldığı antijenlerin biyolojik işlevlerini ve kanserle ilişkilerini daha ayrıntılı şekilde inceleyerek, model çıktılarının biyolojik temellerini güçlendirebilir.

13.Conclusion

Bu çalışma, serum bazlı otoantikor profillerinin akciğer kanseri riskinin erken aşamada değerlendirilmesi için kullanılabilir bir biyolojik sinyal kaynağı sunduğunu göstermektedir. Elde edilen sonuçlar, otoantikor verilerinin kanser ve kanser olmayan bireyler arasında rastgele olmayan, anlamlı bir ayrım bilgisi içerdiğini ortaya koymaktadır.

Bununla birlikte, geliştirilen modelin amacı kesin tanı koymak değil; **tarama odaklı bir risk sinyali üretmektir**. Olasılık temelli çıktı yapısı ve karar eşiğinin ayarlanabilir olması, modelin farklı klinik senaryolara uyarlanabilmesine olanak tanımaktadır. Bu esneklik, otoantikor temelli yaklaşımların gerçek dünya tarama uygulamalarına entegre edilebilmesi açısından önemli bir avantajdır.

Sonuç olarak, bu çalışma otoantikor profillerinin erken risk değerlendirmesi bağlamında potansiyelini ortaya koymakta; aynı zamanda bu tür biyobelirteç temelli modellerin dikkatli veri seçimi, yorumlanabilir modelleme ve kullanım amacına uygun değerlendirme stratejileri ile ele alınması gerektiğini vurgulamaktadır. Daha geniş ve bağımsız veri setleriyle yapılacak gelecekteki çalışmalar, bu yaklaşımın klinik uygulamaya taşınabilmesi için gerekli bir sonraki adımı oluşturacaktır.